

# Application of OPTICS and ensemble learning for Database Intrusion

Поляков Степан, Грицаенко Александра, Екатерина Степура, Слипченко Вера,  
Хугаева Дана, Рублева Вита, Тихомирова Алина

# Актуальность

- Базы данных – ядро информационных систем
- Хранят критически важные сведения (финансы, клиенты, наука)
- Потери организаций ≈ 5% дохода/год (ACFE, 2016)
- Атаки бывают внешние и внутренние

# Проблема

Внешний атакующий	База данных	Внутренний атакующий
уязвимости, слабые пароли		злоупотребление правами

Стандартная защита:

- аутентификация
- контроль доступа
- пароли
- firewall (межсетевые экраны)
- шифрование



НЕДОСТАТОЧНО

# Системы DIDS

Ключевые требования:

- высокая точность
- низкий уровень ложных срабатываний
- надежность и скорость
- работа в реальном времени

# Существующие подходы

Год	Метод	Описание	Методы
2015	ANFIS (нейро-нечёткие правила), <i>Brahma &amp; Panigrahi</i>	Система на основе нейро-нечёткой логики. Строит правила поведения пользователей, транзакции вне правил считаются подозрительными.	ANFIS – Adaptive Neuro-Fuzzy Inference System; Нечёткая логика – работа с неопределённостью; Нейронные сети.
2016	Ассоциативные правила + кластеризация, <i>Singh et al.</i>	Используются ассоциативные правила для профиля пользователей и кластеризация для объединения схожих транзакций.	Ассоциативные правила – закономерности вида 'если A, то B'; Кластеризация – группировка объектов по схожести.
2016	PCA + Random Forest, <i>Ronao &amp; Cho</i>	PCA уменьшает размерность данных, Random Forest классифицирует транзакции, выявляя аномалии.	PCA – метод главных компонент; Random Forest – ансамбль деревьев решений.

# Существующие подходы

Год	Метод	Описание	Методы
2017	CNN + система правил LCS, <i>Bu &amp; Cho</i>	Гибридный метод: система правил LCS выделяет аномалии, CNN уточняет классификацию.	CNN – свёрточная нейросеть; LCS – система обучающихся классификаторов.
2018	Квантовые протоколы, <i>Wei et al.</i>	Применение квантовой криптографии для защиты транзакций и запросов.	Квантовая криптография – методы защиты на основе квантовой механики.
2018	Контроль доступа по схеме БД, <i>Yesin et al.</i>	Использование структуры базы данных для построения правил доступа.	Контроль доступа – система разрешений для пользователей.
2018	Наивный Байес для SQL-запросов, <i>Jayaprakash &amp; Kandasamy</i>	Применение Наивного Байеса для классификации SQL-запросов как нормальных или атакующих.	Наивный Байес – вероятностный метод классификации, предполагающий независимость признаков.

# Основная проблема

- IDS часто генерирует слишком много тревог
- Эффект базовой частоты (Axelsson, 2000)

Даже редкие атаки -> низкая эффективность IDS, если высокий уровень ложноположительных результатов

# Зачем нужен новый подход?

Необходим метод, который:

- сохраняет высокую точность
- уменьшает количество ложных тревог

Предложение авторов:

- кластеризация OPTICS (поиск аномалий)
- ансамблевое обучение (устойчивая классификация)

# Обзор используемых методов - Кластеризация с использованием OPTICS

**Вход:**

$\epsilon$  — радиус окрестности

MinPts — минимальное количество точек, необходимое для образования кластера.

**Выход:**

Упорядоченная последовательность точек, отражающая структуру кластеризации

**Основная идея алгоритма OPTICS:** Для каждого объекта  $k$  в кластере существует как минимум MinPts объектов в его  $\epsilon$ -окрестности.

**Ядровая точка** – объект, в  $\epsilon$ -окрестности которого находится как минимум MinPts объектов ( $\geq \text{MinPts}$ ).

$$cd_{\epsilon,\text{Minpts}}(k) = \begin{cases} \text{undefined} & \text{if } |N_\epsilon(k)| < \text{MinPts} \\ \text{Minpts\_distance}(k) & \text{otherwise} \end{cases}$$

$$rd_{\epsilon,\text{Minpts}}(k, q) = \begin{cases} \text{undefined} & \text{if } |N_\epsilon(k)| < \text{MinPts} \\ \max(cd(q), dist(q, k)) & \text{otherwise} \end{cases}$$

$$lrd_{\text{MinPts}}(k) = 1 / \frac{\sum_{o \in N_{\text{MinPts}}(k)} rd_{\infty, \text{MinPts}}(k, o)}{|N_{\text{MinPts}}(k)|}$$

$$OF_{\text{MinPts}}(k) = \frac{\sum_{o \in N_{\text{MinPts}}(k)} lrd_{\text{MinPts}}(o)}{|N_{\text{MinPts}}(k)|}$$

# Обзор используемых методов - Ансамблевое обучение

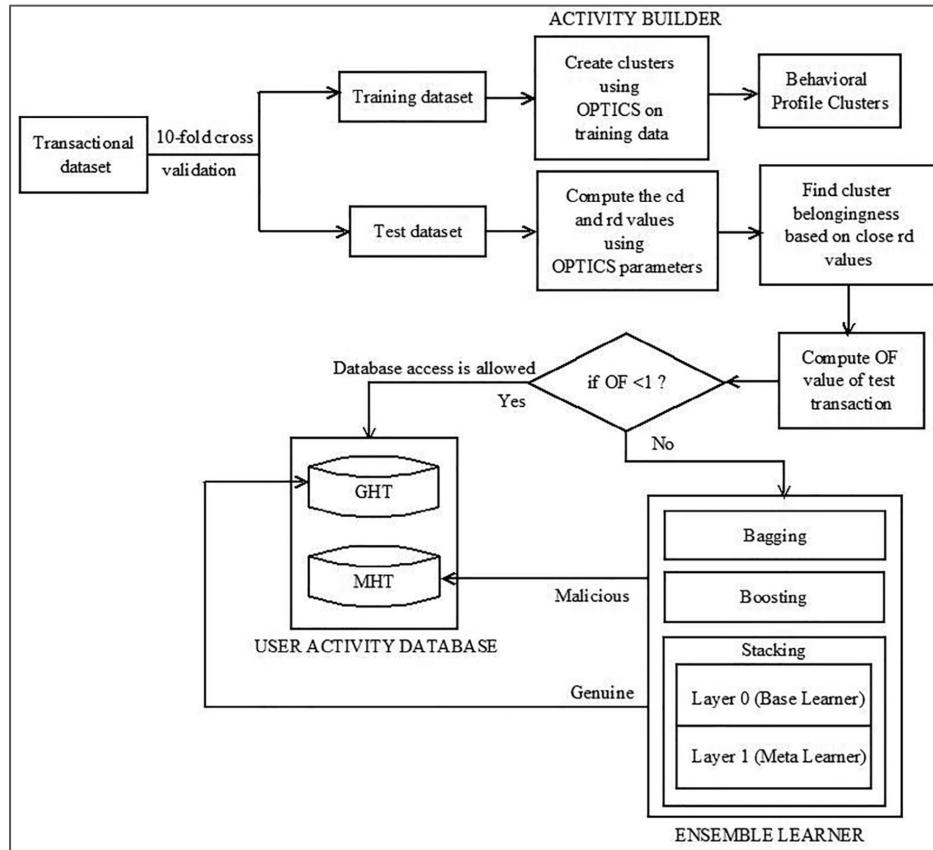
**Ансамбль** – комбинация или агрегирование нескольких классификаторов.

Снижение риска увеличения числа ложноположительных результатов за счёт выбора удачного сочетания разных классификаторов.

## Типы ансамблевых методов:

- **Bagging** — метод построения ансамбля, при котором на разных подвыборках обучаются одинаковые базовые модели. Предсказания комбинируются путём усреднения или голосования.
- **Boosting** — итеративное построение ансамбля, где каждая следующая модель обучается на ошибках предыдущих. Ошибочно классифицированные объекты получают больший вес. Предсказания объединяются с учётом весов моделей.
- **Stacking** — ансамбль, состоящий из разнородных базовых моделей. Их предсказания используются в качестве признаков для обучения метамодели («модели второго уровня»).

## **Предложенный подход**



# Activity Builder — модуль построения активности

Построение профилей пользователей базы данных на основе их прошлых транзакций.

*Транзакция:  $\langle u\_id, transaction\_id, query\_type, table\_list, att\_list, time\_slot, loc, time\_gap \rangle$*

Пользователь с  $u\_id = 10$ :

Q1: SELECT x, y FROM T1 WHERE z = 1  
Q2: DELETE FROM T2 WHERE w = 1

query\_type = {SELECT, DELETE}  
att\_list = {z, x, y, w}  
table\_list = {T1, T2}

transaction\_id = 1  
query\_type {SELECT, DELETE} = {1, 4}  
att\_list {z, x, y, w} = {40, 23, 12, 6}  
table\_list {T1, T2} = {3, 6}  
loc = 1 (из офиса)  
time\_slot = 37 (в интервале с 18:00 до 18:30)  
time\_gap = 21

u_id	transaction_id	query_type	table_list	att_list	time_slot	loc	time_gap
1	10	select	3, 1, 14	1, 6, 2, 3	9	1	4
	11	alter	17, 33	29, 30, 31, 32, 25	12	2	1
2	78	update	10, 4	4, 6, 50	33	1	5

{10, 1, {1,4}, {3,6}, {40,23,12,6}, 37, 1, 21}

# User Activity Database — база активности пользователей

u_id	transaction_id	query_type	table_list	att_list	time_slot	loc	time_gap	label
1	10	select	3, 1, 14	1, 6, 2, 3	9	1	4	genuine
	11	alter	17, 33	29, 30, 31, 32, 25	12	2	1	genuine
2	78	update	10, 4	4, 6, 50	33	1	5	genuine

(a) Genuine History Table (GHT)

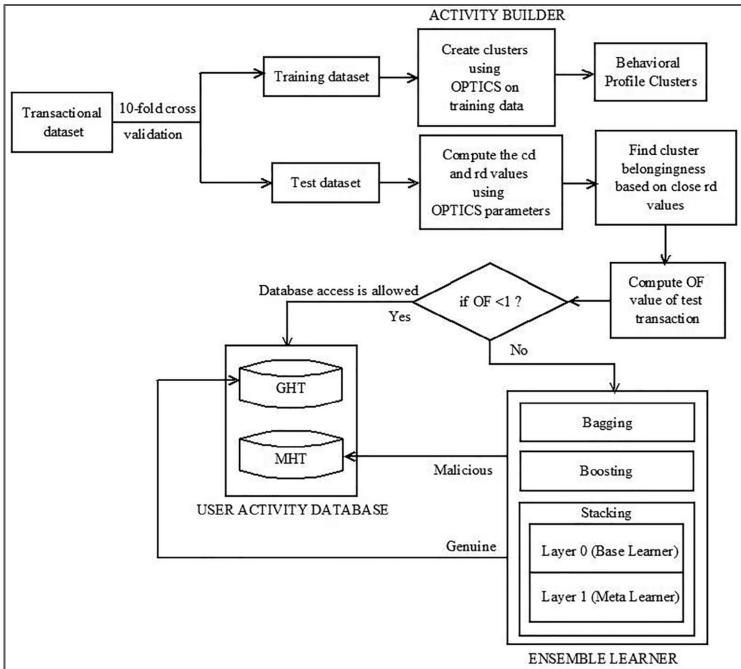
query_type	table_list	att_list	time_slot	loc	time_gap	label
delete	8, 11	16, 24, 5, 16	11	0	2	malicious
alter	55	55, 57, 75, 67	9	2	4	malicious
insert	66	1, 82, 40	27	1	1	malicious

(b) Malicious History Table (MHT)

## **Activity Builder — модуль построения активности**

## Базовые классификаторы:

- Наивный Байесовский классификатор (Naïve Bayes)
  - Дерево решений (Decision Tree, DT)
  - Индукция правил (Rule Induction, RI)
  - Метод k-ближайших соседей (k-NN)
  - Сети с радиальными базисными функциями (Radial Basis Function Network, RBFN)



**Input:**  $D_u[m][n]$ ,  $\varepsilon$ ,  $MinPts$

**Output:** Genuine or Fraud

- 1:  $Norm\_D_u[m][n] = normalize(D_u[m][n])$   $\triangleright$  Data Normalization
- 2:  $[Train[m_1][n], Test[m_2][n]] = divide(Norm\_D_u[m][n])$ 
  - $\triangleright$  Train and Test sets are extracted
  - $\triangleright m = m_1 + m_2$
- 3:  $Prof_u = OPTICS\_cluster(Train[m_1][n_1], \varepsilon, MinPts)$   $\triangleright$  Using Eq. (1)- Eq. (2)
- 4:  $rd[m_2] = OPTICS\_cluster(Test[m_2][n], \varepsilon, MinPts)$ 
  - $\triangleright$  Generate rd values for Incoming transaction
- 5:  $OF[m_2] = OPTICS\_cluster(rd[m_2])$   $\triangleright$  Using Eq.4
- 6: if  $OF[m_2] < 1$  then
- 7:     Output ("Database Access is allowed")
- 8:     Insert\_GHT ( $Test_x$ )  $\triangleright$  Insert  $Test_x$  in GHT
- 9:      $\triangleright Test_x \in Test[m_2][n], x = 1, \dots, m_2$
- 10: else
  - $\triangleright$  EL: Ensemble Learner
- 11: end if
- Collect History Information  $D(U_x)$  about user  $U_x$  from User Activity Database
- EL:
- 12:  $Bag = Bagging(Test_x, Prof_u)$   $\triangleright$  Bag: Bagging model
- 13:  $Boost = Boosting(Test_x, Prof_u)$   $\triangleright$  Boost: Boosting model
- 14:  $Stack = Stacking(Test_x, Prof_u)$   $\triangleright$  Stack: Stacking model
- 15: if  $(Test_x \in Bag) \parallel (Test_x \in Boost) \parallel (Test_x \in Stack)$  then
- 16:     Insert\_GHT ( $Test_x$ )  $\triangleright$  Insert  $Test_x$  in GHT
- 17:     Output ("Genuine")
- 18: else
  - $\triangleright$  Insert  $Test_x$  in MHT
- 19:     Insert\_MHT ( $Test_x$ )
- 20:     Output ("Malicious")
- 21: end if

# Экспериментальные данные

- Использован симулятор транзакций с тремя модулями:
  - GTGM – генерация нормальных действий.
  - MTGM – моделирование атакующих транзакций.
  - MMRPM – управление частотой и структурой потоков.
- Итоговый объём данных: 41 390 транзакций (нормальные + атакующие).

# Настройка OPTICS

- OPTICS применяется для кластеризации транзакций и выделения профилей нормального поведения.
- Для подбора оптимальных параметров исследовались комбинации MinPts и  $\epsilon$ .
- Наилучшие результаты получены при MinPts = 10,  $\epsilon$  = 0.
- Обеспечили минимальное число ложных тревог.

Performance of OPTICS with Different Parameter Values.

Performance Metrics (in %)	Parameter Values					
	Minpts = 10 $\epsilon$ = 0	Minpts = 10 $\epsilon$ = 5	Minpts = 50 $\epsilon$ = 0	Minpts = 50 $\epsilon$ = 5	Minpts = 100 $\epsilon$ = 0	Minpts = 100 $\epsilon$ = 5
Accuracy	<b>56.34</b>	56.24	58.37	58.27	62.58	62.48
Precision	<b>69.90</b>	69.80	68.40	68.30	66.43	66.33
F1_Score	<b>50.73</b>	50.60	53.63	53.53	62.30	62.20
TPR	<b>58.79</b>	58.69	60.12	60.02	64.30	64.20
FPR	<b>34.73</b>	35.09	34.94	34.84	37.11	38.46

# Сравнение классификаторов и ансамблей

- Проверялись пять алгоритмов: Naïve Bayes, Decision Tree, Rule Induction, k-NN, RBFN.
- При индивидуальном применении модели показывали средние результаты.
- Использование ансамблевых методов (Bagging, Boosting) повысило эффективность:
  - увеличилась точность классификации;
  - снизился уровень ложных тревог.
- Наиболее стабильные показатели зафиксированы у k-NN и RBFN.

# Stacking

- Реализована архитектура stacking.
- Этот подход обеспечил наилучшее качество среди всех методов.
- Stacking показал преимущество в точности и устойчивости по сравнению с одиночными классификаторами и другими ансамблями.

## **Сравнение с существующими подходами**

- Проведено сравнение с ANFIS-DIDS и PCA-WRF.
- Новый метод показал преимущество по всем ключевым критериям.
- Дополнительное преимущество — меньшие вычислительные затраты за счёт фильтрации транзакций на этапе OPTICS.

# Заключение

- Разработанная система объединяет кластеризацию OPTICS и ансамблевые методы обучения.
- Достоинства подхода:
  - высокая точность обнаружения атак,
  - снижение числа ложных срабатываний,
  - меньшая вычислительная сложность по сравнению с существующими решениями.
- Предложенный метод можно рассматривать как эффективный и перспективный инструмент для построения систем обнаружения вторжений в базы данных.