

OPTICS: Ordering Points To Identify the Clustering Structure

Mihael Ankerst, Markus M. Breunig, Hans-Peter Kriegel, Jörg Sander


В чем мотивация?

Еще до статьи существовало множество алгоритмов кластеризации, но их объединяли 3 связанные друг с другом проблемы:


- Они требуют гиперпараметры (например количество кластеров), которые довольно сложно подобрать, особенно для высокоразмерных данных
- При этом модель еще очень чувствительна к подбору гиперпараметров
- И высокоразмерные данные довольно часто имеют какое-то смещенное распределение, которое не описывается одним набором гиперпараметров.

Обзор предыдущих решений

Иерархические(Single-link)




Grid-based clustering




Обзор предыдущих решений

CURE




K-means (K-modes, K-medoids)




Обзор существующих решений

DBSCAN




BIRCH



Предпосылки к оптиксу

1. Почему мы просто не используем какую глобальную плотность?
 - a. Потому, что мы таким образом утверждаем, что у нас все кластеры одинаковой примерно плотности, и возникает проблема нахождения этой лучшей плотности
2. Использовать другие методы, например **single-link**
 - a. Конкретно **single-link**, имеет плохую привычку строить очень длинные, но тонкие кластеры (хотя в некоторых случаях это может быть полезно)
 - b. И эвристические методы в целом сложнее анализировать



Определения

ϵ — максимальное расстояние для создания кластера

$MinPts$ — минимальное кол-во точек в ϵ -окрестности

$N_\epsilon(p)$ — точки в ϵ -окрестности

Directly Density-Reachable

Объект p напрямую достижим из объекта q , если:

1. $p \in N_\epsilon(q)$
2. $|N_\epsilon(q)| \geq MinPts$ (условие ядрового объекта)

Density-Reachable

Объект p достижим из объекта q ,


если существует набор p_1, \dots, p_n , таких, что:

1. $p_1 = p, p_n = q$
2. p_i достижим из p_{i+1}

D — множество всех точек

Density-Connected

Объект p связан с объектом q , если:
существует такой объект o ,
что из o достижим и p , и q



Определения

Cluster and noise

Множество C называется кластером, если:

1. $\forall p, q \in D$, если $p \in C$ и q достижимо из p , то $q \in C$
2. $\forall p, q \in C$, p и q связаны

Любой объект, не принадлежащий ни одному кластеру является шумом

Core Distance

$$cd_{\epsilon, MinPts}(p) = \begin{cases} \text{UNDEFINED}, |N_\epsilon(p)| < MinPts \\ distance_{MinPts}(p), \text{otherwise} \end{cases}$$

Где $distance_{MinPts}(p)$ дистанция до $MinPts$ -близайшей точки от p

Reachability Distance

$$rd_{\epsilon, MinPts}(p, o) = \begin{cases} \text{UNDEFINED}, |N_\epsilon(o)| < MinPts \\ \max(cd(o), distance(o, p)), \text{otherwise} \end{cases}$$


Ядровая дистанция - по факту минимальный эпсилон, при котором Р могла быть ядровой точкой

Reachability distance - по факту минимальный эпсилон, при котором Р могла быть напрямую достижима из О

Ordering

Идея OPTICS в том, что кластеры с меньшим эпсилон (большой плотностью) будут полностью подкластерами кластеров с меньшей плотностью.

Из этого следует идея, о том, что мы можем как-нибудь упорядочить точки, чтобы в итоге мы рассматривали кластеры с наибольшей плотностью раньше, чтобы например потом при использовании измененного DBSCAN'a, мы могли с любой плотностью создавать кластеры



Сам алгоритм $O(n * |\text{время обработки одной окрестности}|)$. В худшем: $O(n^2)$

```
function OPTICS(DB, ε, MinPts) is
    for each point p of DB do
        p.reachability-distance = UNDEFINED
    for each unprocessed point p of DB do
        N = getNeighbors(p, ε)
        mark p as processed
        output p to the ordered list
        if core-distance(p, ε, MinPts) != UNDEFINED then
            Seeds = empty priority queue
            update(N, p, Seeds, ε, MinPts)
            for each next q in Seeds do
                N' = getNeighbors(q, ε)
                mark q as processed
                output q to the ordered list
                if core-distance(q, ε, MinPts) != UNDEFINED do
                    update(N', q, Seeds, ε, MinPts)
```

```
function update(N, p, Seeds, ε, MinPts) is
    coredist = core-distance(p, ε, MinPts)
    for each o in N
        if o is not processed then
            new-reach-dist = max(coredist, dist(p,o))
            if o.reachability-distance == UNDEFINED then // o is not in Seeds
                o.reachability-distance = new-reach-dist
                Seeds.insert(o, new-reach-dist)
            else // o in Seeds, check for improvement
                if new-reach-dist < o.reachability-distance then
                    o.reachability-distance = new-reach-dist
                    Seeds.move-up(o, new-reach-dist)
```

Extract

```
ExtractDBSCAN-Clustering (ClusterOrderedObjs,ε', MinPts)
// Precondition: ε' ≤ generating dist ε for ClusterOrderedObjs
ClusterId := NOISE;
FOR i FROM 1 TO ClusterOrderedObjs.size DO
    Object := ClusterOrderedObjs.get(i);
    IF Object.reachability_distance > ε' THEN
        // UNDEFINED > ε
        IF Object.core_distance ≤ ε' THEN
            ClusterId := nextId(ClusterId);
            Object.clusterId := ClusterId;
        ELSE
            Object.clusterId := NOISE;
        ELSE // Object.reachability_distance ≤ ε'
            Object.clusterId := ClusterId;
    END; // ExtractDBSCAN-Clustering
```

Визуализация кластерной структуры данных методом OPTICS и производные графические техники

1. Что выдаёт OPTICS ?

упорядочивание объектов $o : \{1..n\} \rightarrow DB$;
и значения достижимостей $r : \{1..n\} \rightarrow \mathbb{R}_{\geq 0}$.

Синтетические данные: кластеры разной плотности и шум






Figure 9. Illustration of the cluster-ordering

2. Параметры и их влияние




Figure 10. Effects of parameter settings on the cluster-ordering

ϵ — максимальный радиус

MinPts — минимальное число точек в окрестности






Figure 11. Part of the reachability-plot for 1,024-d image data

$$\text{Volume}_{S(r)} = \frac{\sqrt{\pi^d}}{\Gamma(\frac{d}{2} + 1)} \times r^d$$

$$r = \sqrt[d]{\frac{\text{Volume}_{DS} \times k \times \Gamma(\frac{d}{2} + 1)}{N \times \sqrt{\pi^d}}}.$$

$$\text{Volume}_S = \frac{\text{Volume}_{DS}}{N} \times k$$

Initialization
Processed: 0/120



3. Attribute-plot




Figure 13. Reachability-plot and attribute-plot for 9-d data from weather stations




Figure 12. Reachability-plots for a data set with hierarchical clusters of different sizes, densities and shapes

4. Большие данные и *Circle Segments*




Figure 14. The Circle Segments technique for 8-d data

- 1) круг разбивают на сегменты — по одному на атрибут (рис. 14);
- 2) упорядочивание берут из OPTICS (это и есть «сортировка»);
- 3) значения (DV) кодируют яркостью/цветом;
- 4) вводится параметр Resolution;
- 5) используется градация серого, чтобы прогрессия яркости коррелировала с достижимостью (тёмное — малые расстояния, т.е. плотные «внутри кластера» участки).





Figure 15. Clustering structure of 30,000 16-d objects

Automatic Techniques in OPTICS

- OPTICS строит *reachability plot* — график достижимости.
- Кластеры выглядят как «долины» — низкие значения → высокая плотность.
- Раньше кластеры выделяли вручную.
- Цель — научить алгоритм делать это автоматически.



Formal Cluster Boundaries: Steep Points and Areas

- Если точка резко падает вниз по значению достижимости — это называется ξ -steep downward point, то есть точка резкого спада. Это признак начала кластера — график уходит вниз, значит плотность растёт.
- Если точка наоборот резко поднимается вверх, это ξ -steep upward point — точка резкого подъёма. Это значит, что плотность уменьшается, и мы выходим из кластера.
- Steep Area — последовательность таких точек.
- Кластер = область между спадом и подъёмом.

Definition 9: (ξ -steep points)

A point $p \in \{1 \dots n - 1\}$ is called a ξ -steep upward point iff it is $\xi\%$ lower than its successor:

$$\text{UpPoint}_{\xi}(p) \Leftrightarrow r(p) \leq r(p + 1) \times (1 - \xi)$$

A point $p \in \{1 \dots n - 1\}$ is called a ξ -steep downward point iff p 's successor is $\xi\%$ lower:

$$\text{DownPoint}_{\xi}(p) \Leftrightarrow r(p) \times (1 - \xi) \leq r(p + 1)$$




Figure 17. Real world clusters

Formal Cluster Boundaries: Steep Points and Areas

Definition 10: (ξ -steep areas)

An interval $I = [s, e]$ is called a ξ -steep upward area

$UpArea_\xi(I)$ iff it satisfies the following conditions:

- s is a ξ -steep upward point: $UpPoint_\xi(s)$
- e is a ξ -steep upward point: $UpPoint_\xi(e)$
- each point between s and e is at least as high as its predecessor:
$$\forall x, s < x \leq e : r(x) \geq r(x - 1)$$

- I does not contain more than $MinPts$ consecutive points that are not ξ -steep upward:

$$\forall [\bar{s}, \bar{e}] \subseteq [s, e] : ((\forall x \in [\bar{s}, \bar{e}] :$$

$$\neg UpPoint_\xi(x)) \Rightarrow \bar{e} - \bar{s} < MinPts)$$

- I is maximal: $\forall J : (I \subseteq J, UpArea_\xi(J) \Rightarrow I = J)$

A ξ -steep downward area is defined analogously
($DownArea_\xi(I)$).

ξ -cluster




Figure 18. Three different types of clusters taken from an industrial parts data set

Definition 11: (ξ -cluster)

An interval $C = [s, e] \subseteq [1, n]$ is called a ξ -cluster iff it satisfies conditions 1 to 4:

$\text{cluster}_\xi(C) \Leftrightarrow \exists D = [s_D, e_D], U = [s_U, e_U]$ with

- 1) $\text{DownArea}_\xi(D) \wedge s \in D$
 - 2) $\text{UpArea}_\xi(U) \wedge e \in U$
 - 3)
 - a) $e - s \geq \text{MinPts}$
 - b) $\forall x, s_D < x < e_U : (r(x) \leq \min(r(s_D), r(e_U)) \times (1 - \xi))$
 - 4) $(s, e) =$

$$\begin{cases} \max\{x \in D \mid r(x) > r(e_U + 1)\}, e_U & \text{if } r(s_D) \times (1 - \xi) \geq r(e_U + 1) \\ (s_D, \min\{x \in U \mid r(x) < r(s_D)\}) & \text{if } r(e_U + 1) \times (1 - \xi) \geq r(s_D) \\ (s_D, e_U) & \text{otherwise} \end{cases}$$

An Efficient Algorithm To Compute All ξ -Clusters

Теперь, когда у нас есть формальное определение, нужно разработать алгоритм, который сможет **найти все такие кластеры автоматически**.

- Алгоритм проходит по графику, ищет пары Down/Up и проверяет условия.
- Благодаря оптимизациям работает эффективно даже на больших данных.

above. The complete algorithm is shown in figure 19. which is

```
SetOfSteepDownAreas = EmptySet
SetOfClusters = EmptySet
index = 0, mib = 0
WHILE(index < n)
    mib = max(mib, r(index))
    IF(start of a steep down area D at index)
        update mib-values and filter SetOfSteepDownAreas(*)
        set D.mib = 0
        add D to the SetOfSteepDownAreas
        index = end of D + 1; mib = r(index)
    ELSE IF(start of steep up area U at index)
        update mib-values and filter SetOfSteepDownAreas
        index = end of U + 1; mib = r(index)
    FOR EACH D in SetOfSteepDownAreas DO
        IF(combination of D and U is valid AND(**)
            satisfies cluster conditions 1, 2, 3a)
            compute [s, e] add cluster to SetOfClusters
    ELSE index = index + 1
RETURN(SetOfClusters)
```

Figure 19. Algorithm ExtractClusters

Experiments




Figure 22. 64- d color histograms auto-clustered for $\xi=0.02$




Figure 20. Scale-up of the ξ -clustering algorithm for the 64- d color histograms




Figure 21. 2- d synthetic data set (left), the reachability-plot (right) and $\xi=0.09$ -clustering (below the reachability-plot)